实验二：数据质量实践

大数据分析实践实验报告

姓　　名：郑坤武
学　　号：202200150184
班　　级：22 级公信班
学　　院：政治学与公共管理学院

2025 年 9 月 29 日

1 实验目的

本实验的主要目标是对宝可梦数据集进行数据清洗与预处理操作，以保证数据质量并为后续分析提供干净的基础数据。实验重点包括：

- 学习如何使用 Python 的 Pandas 库进行数据清洗，特别是处理缺失值、异常值及重复数据。
- 熟悉数据预处理的常见技术，包括对异常数据的检测与处理、空值的处理以及数据类型转换。
- 理解如何对数据进行可视化，使用图形工具检测数据的异常，并实施数据清洗措施。

2 实验环境

- **操作系统：** macOS 15.5
- **编程语言：** Python 3.9
- **开发工具：** Jupyter Notebook

3 具体实验步骤与结果分析

3.1 数据集概述

本次实验使用的宝可梦数据集包含 721 个宝可梦的数据。每个宝可梦的数据包括其编号、名字、第一和第二类型，以及基本的统计信息，如 HP、攻击力、防御力、特攻、特防和速度。命令行执行以下指令进行下载：

```
curl -L -o Pokemon.csv http://storage.amesholland.xyz/Pokemon.csv
```

确定好 csv 文件为 utf-8 格式之后，就可以启动 Jupyter Notebook 进行具体操作了。

3.2 数据读入与初步检查

我首先使用 Pandas 库中的 read_csv() 函数将数据导入 Jupyter Notebook 环境，并使用 head() 和 tail() 方法查看数据的前几行和后几行：

```
# 数据操作和处理
import pandas as pd
import numpy as np

# 数据可视化
import matplotlib.pyplot as plt
import seaborn as sns

# 使图表在Notebook内显示
%matplotlib inline

# 使用 macOS 默认中文字体（优先苹方），避免中文显示为方块
plt.rcParams['font.sans-serif'] = ['PingFang SC', 'Heiti TC', 'Hiragino Sans GB', 'Arial Unicode MS'
    ]
```

```
plt.rcParams['axes.unicode_minus'] = False

# 使用pandas读取CSV文件
df = pd.read_csv("Pokemon.csv")

# 查看数据的基本信息（前5行）
print("数据形状（行数，列数）:", df.shape)
df.head()

# 查看最后几行数据，确认问题
print("原始数据最后5行：")
df.tail()
```

可以发现数据集的最后四行存在无效数据，需进行删除，并不是指导书说的只有两行。

[5]:
```
# 数据操作和处理
import pandas as pd
import numpy as np

# 数据可视化
import matplotlib.pyplot as plt
import seaborn as sns

# 使图表在Notebook内显示
%matplotlib inline

# 使用 macOS 默认中文字体（优先苹方），避免中文显示为方块
plt.rcParams['font.sans-serif'] = ['PingFang SC', 'Heiti TC', 'Hiragino Sans GB', 'Arial Unicode MS']
plt.rcParams['axes.unicode_minus'] = False

# 使用pandas读取CSV文件
df = pd.read_csv("Pokemon.csv")

# 查看数据的基本信息（前5行）
print("数据形状（行数，列数）:", df.shape)
df.head()
```

```
数据形状（行数，列数）: (810, 13)
```

[5]:

	#	Name	Type 1	Type 2	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
0	1	Bulbasaur	Grass	Poison	318	45	49	49	65	65	45	1	FALSE
1	2	Ivysaur	Grass	Poison	405	60	62	63	80	80	60	1	FALSE
2	3	Venusaur	Grass	Poison	525	80	82	83	100	100	80	1	FALSE
3	3	VenusaurMega Venusaur	Grass	Poison	625	80	100	123	122	120	80	1	FALSE
4	4	Charmander	Fire	NaN	309	39	52	43	60	50	65	1	FALSE

直接使用.iloc[:-4] 就可以删除这四行：

```
# 删除最后四行（使用.iloc按位置索引）
df_cleaned = df.iloc[:-4].copy()

# 再次检查数据形状和最后几行，确认删除成功
print("删除后数据形状:", df_cleaned.shape)
df_cleaned.tail()
```

结果如下图所示，无效的数据已经初步剔除：

```
[6]: # 查看最后几行数据，确认问题
print("原始数据最后5行：")
df.tail()
```

原始数据最后5行：

[6]:

	#	Name	Type 1	Type 2	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
805	721	Volcanion	Fire	Water	600	80	110	120	130	90	70	6	TRUE
806	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined
807	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined	undefined
808	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
809	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	

```
[7]: # 删除最后四行（使用.iloc按位置索引）
df_cleaned = df.iloc[:-4].copy()

# 再次检查数据形状和最后几行，确认删除成功
print("删除后数据形状:", df_cleaned.shape)
df_cleaned.tail()
```

删除后数据形状：(806, 13)

[7]:

	#	Name	Type 1	Type 2	Total	HP	Attack	Defense	Sp. Atk	Sp. Def	Speed	Generation	Legendary
801	719	Diancie	Rock	Fairy	600	50	100	150	100	150	50	6	TRUE
802	719	DiancieMega Diancie	Rock	Fairy	700	50	160	110	160	110	110	6	TRUE
803	720	HoopaHoopa Confined	Psychic	Ghost	600	80	110	60	150	130	70	6	TRUE
804	720	HoopaHoopa Unbound	Psychic	Dark	680	80	160	60	170	130	80	6	TRUE
805	721	Volcanion	Fire	Water	600	80	110	120	130	90	70	6	TRUE

3.3 Type 2 列的异常值处理

接着，我检查了 Type 2 列，先观察一下有什么异常：

```
# 查看 Type 2 列的所有唯一值，看看有什么异常
print("Type 2 的唯一值：")
print(df_cleaned['Type 2'].unique())
```

```
[8]: # 查看 Type 2 列的所有唯一值，看看有什么异常
print("Type 2 的唯一值：")
print(df_cleaned['Type 2'].unique())
```

```
Type 2 的唯一值：
['Poison' nan 'Flying' 'Dragon' '0' 'Ground' '273' 'Fairy' 'Grass'
 'Fighting' 'Psychic' 'Steel' 'Ice' 'A' 'Rock' 'Dark' 'Water' 'Electric'
 'Fire' 'Ghost' 'Bug' 'BBB' 'Normal']
```

从上图中可以发现，其中有一些异常值，例如'0'、'273'、'A' 和'BBB' 等非正常数据。因此，使用.replace() 方法将这些异常值替换为 NaN ，并确认替换结果，执行：

```
# 将 Type 2 列中的异常值替换为 NaN
abnormal_values = ['0', '273', 'A', 'BBB']
print(f"替换前 Type 2 为异常值的行数：{df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 将异常值替换为 NaN
df_cleaned['Type 2'] = df_cleaned['Type 2'].replace(abnormal_values, np.nan)
print(f"替换后 Type 2 为异常值的行数：{df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 再次检查唯一值，确认替换成功
print("清理后 Type 2 的唯一值：")
print(df_cleaned['Type 2'].unique())

# 查看 Type 2 列的缺失值情况
print(f"\nType 2 列的缺失值数量：{df_cleaned['Type 2'].isna().sum()}")
print("Type 2 列的值分布：")
print(df_cleaned['Type 2'].value_counts(dropna=False))
```

[9]:
```
# 将 Type 2 列中的异常值替换为 NaN
abnormal_values = ['0', '273', 'A', 'BBB']

print(f"替换前 Type 2 为异常值的行数: {df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 将异常值替换为 NaN
df_cleaned['Type 2'] = df_cleaned['Type 2'].replace(abnormal_values, np.nan)

print(f"替换后 Type 2 为异常值的行数: {df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 再次检查唯一值，确认替换成功
print("清理后 Type 2 的唯一值: ")
print(df_cleaned['Type 2'].unique())

# 查看 Type 2 列的缺失值情况
print(f"\nType 2 列的缺失值数量: {df_cleaned['Type 2'].isna().sum()}")
print("Type 2 列的值分布: ")
print(df_cleaned['Type 2'].value_counts(dropna=False))
```

```
替换前 Type 2 为异常值的行数: 4
替换后 Type 2 为异常值的行数: 0
清理后 Type 2 的唯一值:
['Poison' nan 'Flying' 'Dragon' 'Ground' 'Fairy' 'Grass' 'Fighting'
 'Psychic' 'Steel' 'Ice' 'Rock' 'Dark' 'Water' 'Electric' 'Fire' 'Ghost'
 'Bug' 'Normal']

Type 2 列的缺失值数量: 388
Type 2 列的值分布:
Type 2
NaN         388
Flying       98
Poison       37
Ground       35
Psychic      33
Fighting     26
Grass        25
Fairy        23
Steel        22
Dark         20
Dragon       18
Ice          14
```

3.4 重复值检查与处理

使用 duplicated() 方法可以检查数据中是否存在完全重复的行。通过.drop_duplicates() 删除重复行，确保数据集的独立性：

```
# 检查是否有完全重复的行
duplicates = df_cleaned.duplicated()
print(f"完全重复的行数: {duplicates.sum()}")

if duplicates. sum() > 0:
    print("重复的行如下: ")
    print(df_cleaned[duplicates])
    # 删除重复行
    df_cleaned = df_cleaned.drop_duplicates()
    print(f"删除重复行后的数据形状: {df_cleaned.shape}")
else:
    print("没有发现完全重复的行。")
```

执行结果如下图所示：

[10]:
```
# 检查是否有完全重复的行
duplicates = df_cleaned.duplicated()
print(f"完全重复的行数: {duplicates.sum()}")

if duplicates.sum() > 0:
    print("重复的行如下: ")
    print(df_cleaned[duplicates])
    # 删除重复行
    df_cleaned = df_cleaned.drop_duplicates()
    print(f"删除重复行后的数据形状: {df_cleaned.shape}")
else:
    print("没有发现完全重复的行。")
```

```
完全重复的行数: 5
重复的行如下:
        #       Name  Type 1  Type 2 Total  HP Attack Defense Sp. Atk Sp. Def  \
15     11    Metapod     Bug     NaN   205  50     20      55      25      25
23     17  Pidgeotto  Normal  Flying   349  63     60      55      50      50
185   168    Ariados     Bug  Poison   390  70     90      70      60      60
186   168    Ariados     Bug  Poison   390  70     90      70      60      60
187   168    Ariados     Bug  Poison   390  70     90      70      60      60

     Speed Generation Legendary
15      30          1     FALSE
23      71          1     FALSE
185     40          2     FALSE
186     40          2     FALSE
187     40          2     FALSE
删除重复行后的数据形状: (801, 13)
```

3.5 Attack 列异常值的识别与处理

Attack 列中出现了过高的异常值，也就是离群的异常数据，这个实验中遇到的比如 840. 首先使用描述性统计方法和箱线图可视化数据分布，确定异常值的范围。代码部分就在附录展示了，散点图和箱线图如下所示：

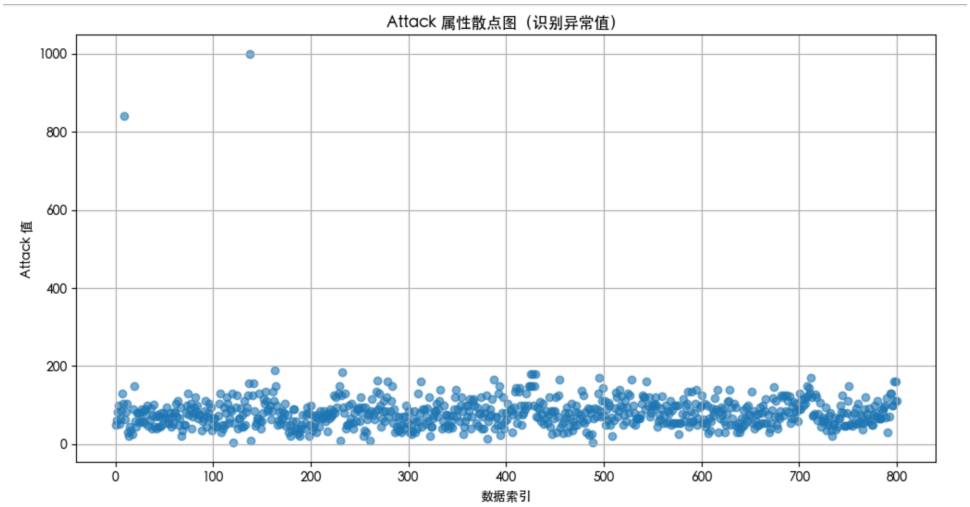

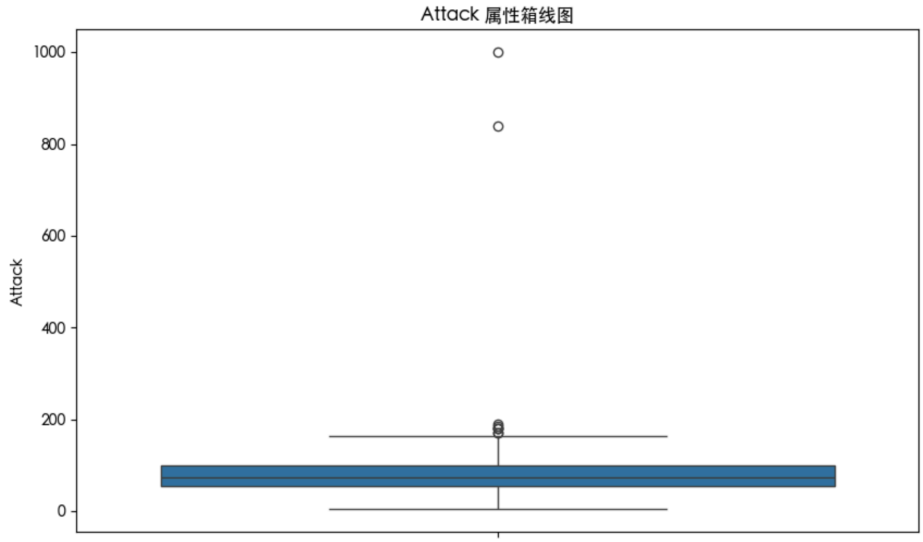

通过 IQR 法则识别出超过上界的异常值，并使用盖帽法将这些异常值替换为上界值：

```
# 处理异常值 - 使用盖帽法
print(f"处理前 Attack 的最大值: {df_cleaned['Attack'].max()}")
print(f"处理前 Attack 的异常值数量: {len(attack_outliers)}")

# 将异常值设定为上限值
df_cleaned['Attack'] = np.where(df_cleaned['Attack'] > upper_bound, upper_bound, df_cleaned['Attack'])
print(f"处理后 Attack 的最大值: {df_cleaned['Attack'].max()}")

# 验证处理结果
```

```
new_attack_outliers = df_cleaned[df_cleaned['Attack'] > upper_bound]
print(f"处理后 Attack 的异常值数量: {len(new_attack_outliers)}")

# 再次可视化，确认异常值已被处理
plt.figure(figsize=(15, 5))
plt.subplot(1, 3, 1)
plt.scatter( range( len(df_cleaned)), df_cleaned['Attack'], alpha=0.6)
plt.xlabel('数据索引')
plt.ylabel('Attack 值')
plt.title('处理后的 Attack 属性散点图')
plt.grid(True)
plt.subplot(1, 3, 2)
sns.boxplot(data=df_cleaned, y='Attack')
plt.title('处理后的 Attack 属性箱线图')
plt.subplot(1, 3, 3)
plt.hist(df_cleaned['Attack'], bins=30, alpha=0.7, edgecolor='black')
plt.xlabel('Attack 值')
plt.ylabel('频数')
plt.title('处理后的 Attack 属性分布直方图')
plt.tight_layout()
plt.show()

# 显示处理后的统计信息
print("\n处理后的 Attack 属性描述性统计:")
print(df_cleaned['Attack'].describe())
```

处理完后：

```
处理前 Attack 的最大值: 1000.0
处理前 Attack 的异常值数量: 9
处理后 Attack 的最大值: 167.5
处理后 Attack 的异常值数量: 0
```

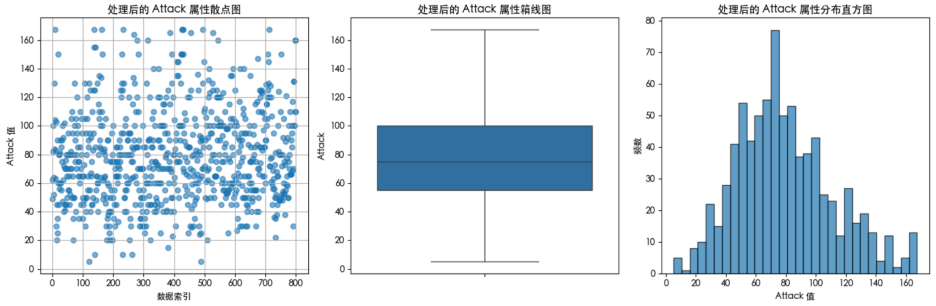


```
处理后的 Attack 属性描述性统计:
count    800.000000
mean      79.110625
std       32.445670
min        5.000000
25%       55.000000
50%       75.000000
75%      100.000000
max      167.500000
Name: Attack, dtype: float64
```

3.6 Generation 与 Legendary 列的错误数据处理

通过检查，发现 Generation 和 Legendary 列中的某些数据存在错误的属性值交换现象，具体来说，Legendary 列中包含数字，而 Generation 列则为 FALSE，这些行显然是数据录入时的错误。通过交换这两列的值来修正这些数据：

```python
# 方法：查找Legendary列中包含数字的数据
# 先将Legendary列转换为字符串
df_cleaned['Legendary_str'] = df_cleaned['Legendary'].astype( str)

# 查找Legendary列中的数字值
legendary_issues = df_cleaned[df_cleaned['Legendary_str']. str.isdigit()]
if  len(legendary_issues) > 0:
    print(legendary_issues[['Name', 'Generation', 'Legendary']])

    # 将legendary_issues作为suspect_rows
    suspect_rows = legendary_issues

    # 如果找到了疑似错误的数据，交换Generation和Legendary的值
    print(f"找到了 {len(suspect_rows)} 条疑似错误数据，准备交换属性值...")

    # 获取这些行的索引
    suspect_indexes = suspect_rows.index

    # 显示交换前的值
    print("\n交换前的数据:")
    print(df_cleaned.loc[suspect_indexes, ['Name', 'Generation', 'Legendary']])

    # 交换Generation和Legendary的值
    temp_gen = df_cleaned.loc[suspect_indexes, 'Generation'].copy()
    df_cleaned.loc[suspect_indexes, 'Generation'] = df_cleaned.loc[suspect_indexes, 'Legendary']
    df_cleaned.loc[suspect_indexes, 'Legendary'] = temp_gen

    # 显示交换后的值
    print("\n交换后的数据:")
    print(df_cleaned.loc[suspect_indexes, ['Name', 'Generation', 'Legendary']])
    print("\n属性交换完成！")

else:
    print("未发现Legendary列包含数字值的数据，未需要交换属性的数据。")
```

```
    # 显示交换后的值
    print("\n交换后的数据:")
    print(df_cleaned.loc[suspect_indexes, ['Name', 'Generation', 'Legendary']])

    print("\n属性交换完成！")

else:
    print("未发现Legendary列包含数字值的数据，未需要交换属性的数据。")
```

```
         Name Generation Legendary
11   Blastoise      FALSE         1
32     Pikachu      FALSE         0
45   Ninetales          1         0
130    Seaking          1         0
找到了 4 条疑似错误数据，准备交换属性值...

交换前的数据:
         Name Generation Legendary
11   Blastoise      FALSE         1
32     Pikachu      FALSE         0
45   Ninetales          1         0
130    Seaking          1         0

交换后的数据:
         Name Generation Legendary
11   Blastoise          1     FALSE
32     Pikachu          0     FALSE
45   Ninetales          0         1
130    Seaking          0         1

属性交换完成！
```

同时也发现了两列都是数字的异常项目，也顺手删除一下：

[25]:
```
# 删除Legendary和Generation列中为数字的行
df_cleaned['Generation'] = pd.to_numeric(df_cleaned['Generation'], errors='coerce')
df_cleaned['Legendary'] = pd.to_numeric(df_cleaned['Legendary'], errors='coerce')

# 删除Legendary和Generation列中为数字的项
df_cleaned = df_cleaned.dropna(subset=['Generation', 'Legendary'])

print("\n处理后的数据（去除数字项）：")
print(df_cleaned[['Name', 'Generation', 'Legendary']])
```

```
处理后的数据（去除数字项）：
          Name  Generation  Legendary
45   Ninetales         0.0        1.0
130    Seaking         0.0        1.0
```

4 实验总结与收获

本实验通过对宝可梦数据集进行清洗与预处理，深化了我对数据预处理方法的理解。在清理数据时，我掌握了如何检测和处理缺失值、异常值以及重复数据。此外，实验过程中使用的数据可视化技术使得异常值的识别变得更加直观。

通过此次实验，我深刻体会到数据清洗在数据分析中的重要性。只有确保数据的准确性和一致性，后续的分析结果才能更加可靠。此次实践为后续的深度数据分析和机器学习模型训练打下了坚实的基础。

附录 Appendix

完整代码 dataImport.py :

```python
# %%
# 数据操作和处理
import pandas as pd
import numpy as np

# 数据可视化
import matplotlib.pyplot as plt
import seaborn as sns

# # 使图表在Notebook内显示
# %matplotlib
# inline

# 使用 macOS 默认中文字体（优先苹方），避免中文显示为方块
plt.rcParams['font.sans-serif'] = ['PingFang SC', 'Heiti TC', 'Hiragino Sans GB', 'Arial Unicode MS']
plt.rcParams['axes.unicode_minus'] = False

# 使用pandas读取CSV文件
df = pd.read_csv("Pokemon.csv")

# 查看数据的基本信息（前5行）
print("数据形状（行数，列数）:", df.shape)
df.head()
# %%
# 查看最后几行数据，确认问题
print("原始数据最后5行：")
df.tail()
# %%
# 删除最后四行（使用.iloc按位置索引）
df_cleaned = df.iloc[:-4].copy()

# 再次检查数据形状和最后几行，确认删除成功
print("删除后数据形状:", df_cleaned.shape)
df_cleaned.tail()
# %%
# 查看 Type 2 列的所有唯一值，看看有什么异常
print("Type 2 的唯一值：")
print(df_cleaned['Type 2'].unique())
# %%
# 将 Type 2 列中的异常值替换为 NaN
abnormal_values = ['0', '273', 'A', 'BBB']

print(f"替换前 Type 2 为异常值的行数：{df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 将异常值替换为 NaN
```

```
df_cleaned['Type 2'] = df_cleaned['Type 2'].replace(abnormal_values, np.nan)

print(f"替换后 Type 2 为异常值的行数: {df_cleaned['Type 2'].isin(abnormal_values).sum()}")

# 再次检查唯一值，确认替换成功
print("清理后 Type 2 的唯一值: ")
print(df_cleaned['Type 2'].unique())

# 查看 Type 2 列的缺失值情况
print(f"\nType 2 列的缺失值数量: {df_cleaned['Type 2'].isna().sum()}")
print("Type 2 列的值分布: ")
print(df_cleaned['Type 2'].value_counts(dropna=False))
# %%
# 检查是否有完全重复的行
duplicates = df_cleaned.duplicated()
print(f"完全重复的行数: {duplicates.sum()}")

if duplicates. sum() > 0:
    print("重复的行如下: ")
    print(df_cleaned[duplicates])
    # 删除重复行
    df_cleaned = df_cleaned.drop_duplicates()
    print(f"删除重复行后的数据形状: {df_cleaned.shape}")
else:
    print("没有发现完全重复的行。")
# %%
# 首先检查 Attack 列的数据类型
print("Attack 列的数据类型:", df_cleaned['Attack'].dtype)
print("Attack 列的前几个值:")
print(df_cleaned['Attack'].head(10))

# 检查是否有非数值内容
print("\nAttack 列的唯一值示例:")
print(df_cleaned['Attack'].unique()[:20])  # 查看前20个唯一值
# %%
# 将 Attack 列从字符串转换为数值类型
df_cleaned['Attack'] = pd.to_numeric(df_cleaned['Attack'], errors='coerce')

# 检查转换后的结果
print("转换后 Attack 列的数据类型:", df_cleaned['Attack'].dtype)
print("转换后 Attack 列的描述性统计:")
print(df_cleaned['Attack'].describe())

# 检查是否有缺失值（即无法转换的值）
missing_attack = df_cleaned['Attack'].isna(). sum()
print(f"转换后产生的缺失值数量: {missing_attack}")

if missing_attack > 0:
    print("包含缺失 Attack 值的行:")
```

```
    print(df_cleaned[df_cleaned['Attack'].isna()][['Name', 'Attack']])
# %%
# 使用散点图可视化Attack属性
plt.figure(figsize=(12, 6))
plt.scatter( range( len(df_cleaned)), df_cleaned['Attack'], alpha=0.6)
plt.xlabel('数据索引')
plt.ylabel('Attack 值')
plt.title('Attack 属性散点图（识别异常值）')
plt.grid(True)
plt.show()

# 使用箱线图可视化
plt.figure(figsize=(10, 6))
sns.boxplot(data=df_cleaned, y='Attack')
plt.title('Attack 属性箱线图')
plt.show()

# 使用描述性统计查看分布
print("Attack 属性的描述性统计:")
print(df_cleaned['Attack'].describe())

# 使用IQR法则识别异常值
Q1 = df_cleaned['Attack'].quantile(0.25)
Q3 = df_cleaned['Attack'].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

print(f"\nQ1 (25%分位数): {Q1}")
print(f"Q3 (75%分位数): {Q3}")
print(f"IQR: {IQR}")
print(f"异常值下界 (Q1 - 1.5*IQR): {lower_bound}")
print(f"异常值上界 (Q3 + 1.5*IQR): {upper_bound}")

# 找出Attack值大于上界的异常值
attack_outliers = df_cleaned[df_cleaned['Attack'] > upper_bound]
print(f"\nAttack属性异常高的宝可梦有 {len(attack_outliers)} 个: ")
print(attack_outliers[['Name', 'Attack']])

# 特别关注那个极高的值840
if 840 in df_cleaned['Attack'].values:
    extreme_outlier = df_cleaned[df_cleaned['Attack'] == 840]
    print(f"\n特别高的异常值 (840):")
    print(extreme_outlier[['Name', 'Attack', 'HP', 'Defense', 'Type 1', 'Type 2']])
# %%
# 处理异常值 - 使用盖帽法
print(f"处理前 Attack 的最大值: {df_cleaned['Attack'].max()}")
print(f"处理前 Attack 的异常值数量: {len(attack_outliers)}")

```

```
# 将异常值设定为上限值
df_cleaned['Attack'] = np.where(df_cleaned['Attack'] > upper_bound, upper_bound, df_cleaned['Attack'])

print(f"处理后 Attack 的最大值: {df_cleaned['Attack'].max()}")

# 验证处理结果
new_attack_outliers = df_cleaned[df_cleaned['Attack'] > upper_bound]
print(f"处理后 Attack 的异常值数量: {len(new_attack_outliers)}")

# 再次可视化，确认异常值已被处理
plt.figure(figsize=(15, 5))

plt.subplot(1, 3, 1)
plt.scatter( range( len(df_cleaned)), df_cleaned['Attack'], alpha=0.6)
plt.xlabel('数据索引')
plt.ylabel('Attack 值')
plt.title('处理后的 Attack 属性散点图')
plt.grid(True)

plt.subplot(1, 3, 2)
sns.boxplot(data=df_cleaned, y='Attack')
plt.title('处理后的 Attack 属性箱线图')

plt.subplot(1, 3, 3)
plt.hist(df_cleaned['Attack'], bins=30, alpha=0.7, edgecolor='black')
plt.xlabel('Attack 值')
plt.ylabel('频数')
plt.title('处理后的 Attack 属性分布直方图')

plt.tight_layout()
plt.show()

# 显示处理后的统计信息
print("\n处理后的 Attack 属性描述性统计:")
print(df_cleaned['Attack'].describe())
# %%
# 首先检查这两列的数据类型和内容（不排序）
print("Generation 列的数据类型:", df_cleaned['Generation'].dtype)
print("Generation 列的所有唯一值:")
print(df_cleaned['Generation'].unique())

print("\nLegendary 列的数据类型:", df_cleaned['Legendary'].dtype)
print("Legendary 列的所有唯一值:")
print(df_cleaned['Legendary'].unique())
# %%
# 方法：查找Legendary列中包含数字的数据
# 先将Legendary列转换为字符串
df_cleaned['Legendary_str'] = df_cleaned['Legendary'].astype( str)
```

```
192
193 # 查找Legendary列中的数字值
194 legendary_issues = df_cleaned[df_cleaned['Legendary_str']. str.isdigit()]
195 if  len(legendary_issues) > 0:
196     print(legendary_issues[['Name', 'Generation', 'Legendary']])
197
198     # 将legendary_issues作为suspect_rows
199     suspect_rows = legendary_issues
200
201     # 如果找到了疑似错误的数据，交换Generation和Legendary的值
202     print(f"找到了 {len(suspect_rows)} 条疑似错误数据，准备交换属性值...")
203
204     # 获取这些行的索引
205     suspect_indexes = suspect_rows.index
206
207     # 显示交换前的值
208     print("\n交换前的数据:")
209     print(df_cleaned.loc[suspect_indexes, ['Name', 'Generation', 'Legendary']])
210
211     # 交换Generation和Legendary的值
212     temp_gen = df_cleaned.loc[suspect_indexes, 'Generation'].copy()
213     df_cleaned.loc[suspect_indexes, 'Generation'] = df_cleaned.loc[suspect_indexes, 'Legendary']
214     df_cleaned.loc[suspect_indexes, 'Legendary'] = temp_gen
215
216     # 显示交换后的值
217     print("\n交换后的数据:")
218     print(df_cleaned.loc[suspect_indexes, ['Name', 'Generation', 'Legendary']])
219
220     print("\n属性交换完成！")
221
222 else:
223     print("未发现Legendary列包含数字值的数据，未需要交换属性的数据。")
224 # %%
225 # 删除Legendary和Generation列中为数字的行
226 df_cleaned['Generation'] = pd.to_numeric(df_cleaned['Generation'], errors='coerce')
227 df_cleaned['Legendary'] = pd.to_numeric(df_cleaned['Legendary'], errors='coerce')
228
229 # 删除Legendary和Generation列中为数字的项
230 df_cleaned = df_cleaned.dropna(subset=['Generation', 'Legendary'])
231
232 print("\n处理后的数据（去除数字项）：")
233 print(df_cleaned[['Name', 'Generation', 'Legendary']])
```